PRUEBA TÉCNICA

Análisis Integral de Datos:

EDA, Segmentación de Clientes y Modelo Predictivo de Rentabilidad

Desarrollar un análisis integral sobre un dataset de ventas que permita identificar patrones de comportamiento, segmentar clientes por valor y construir un modelo predictivo capaz de anticipar la rentabilidad de cada venta, apoyando la toma de decisiones basada en datos.

Python 3.11 · pandas · scikit-learn · K-Means · Gradient Boosting · MariaDB · Power BI

2

Stack Tecnológico

Herramientas y librerías utilizadas en el proyecto

Lenguaje y Entorno

- Python 3.11
- Anaconda / Jupyter Notebooks

Datos y Base de Datos

- pandas, numpy
- SQLAlchemy + PyMySQL
- MariaDB (Star Schema)

Machine Learning

- scikit-learn (K-Means, GB, RF, LR)
- imbalanced-learn (SMOTE)
- joblib (serialización)

Visualización

- matplotlib + seaborn

Utilidades

- python-dotenv (credenciales)
- Git (control de versiones)

3 Limpieza de Datos

Problemas detectados y corregidos en cada tabla

Sales	Sales/Profit como texto · 3 valores absurdos (hasta $199B) · 4 fechas con año incorrecto (2031/2033) · 1 Discount=10 · 1 Quantity=77,777
Customer	804 filas duplicadas (dataset real tenía la mitad) · 2 edades imposibles (260 y 115 años) · campos texto inválidos en salary y marital_status
Regional Manager	4 errores tipográficos en nombres de región ('Wes t', 'east', 'cenntral') — JOINs fallaban silenciosamente
Returns	504 de 800 filas duplicadas por Order_ID — tasa de devolución aparente era casi 3× la real
Country/Region	71 valores nulos corregidos

3

Base de Datos — Star Schema

sales_db: una tabla de hechos central con 4 dimensiones

dim_customer

804 clientes

dim_product

1,894 productos

fact_sales

10,187 transacciones

Sales · Profit · Discount · Quantity

dim_regional_manager

4 gerentes

dim_returns

296 devoluciones

(LEFT JOIN)

Adicionalmente: sales_raw conserva las tablas originales sin modificar para auditoría y trazabilidad.

4

Análisis Exploratorio de Datos (EDA)

5 dimensiones de análisis sobre el dataset de ventas

📊 **Distribuciones**	Sales, Profit, Discount, Quantity — identificación del segmento premium: top 15% genera el 70% del revenue.
💸 **Descuento → Profit**	Confirmación empírica: descuentos >20% rompen la rentabilidad. Base teórica del modelo ML.
🗂️ **Categorías y Regiones**	Ventas y profit por Categoría, Sub-Categoría, Región y Ship Mode. Tables y Bookcases con profit total negativo.
📅 **Evolución 2020–2023**	Tendencia anual por categoría, estacionalidad mensual. Paradoja Q4: mayor volumen, menor margen.
↩ **Devoluciones + Correlación**	Tasa global y por categoría/región. Matriz de correlación: Discount = mayor correlación negativa con Profit.

4

EDA — Hallazgos Clave

Los tres descubrimientos más relevantes del análisis exploratorio

01

Segmento Premium

"El 15% de los pedidos (Sales > $389) concentra el 70.6% del revenue total. La distribución de ventas presenta asimetría positiva severa — la media supera la mediana en más del 90%." — la media supera la mediana en más del 90%.

02

Punto de Quiebre del Descuento

Descuentos superiores al 20–30% (según categoría) generan pérdidas directas. El 100% de las ventas con descuento ≥50% son no rentables.

03

Paradoja Q4

Noviembre y Diciembre concentran el mayor volumen de ventas del año, pero registran los márgenes más bajos por descuentos excesivos durante la temporada alta.

5

Insight 1 — Política de Descuentos por Categoría

Análisis del profit promedio por tramo de descuento en cada categoría

Categoría	Punto de Quiebre	Límite Recomendado	Impacto
Furniture	20–30%	**máx 10%**	Más sensible — descuentos >20% destruyen valor
Technology	30–40%	**máx 20%**	Mayor margen base — tolera algo más de descuento
Office Supplies	20–30%	**máx 15%**	Alta rotación — control estricto en volumen

💡 Recomendación: Implementar topes duros de descuento por categoría en el sistema de ventas. Furniture es la más crítica — cualquier descuento superior al 10% impacta directamente la rentabilidad.

5

Insight 2 — Matriz BCG por Sub-Categoría

Clasificación por CAGR 2020–2023 vs participación en el profit total

⭐ STARS

Alto CAGR · Alta participación

→ Priorizar inversión

Descuentos controlados

🐄 CASH COWS

Bajo CAGR · Alta participación

→ Mantener márgenes

No sacrificar precio

❓ QUESTION MARKS

Alto CAGR · Baja participación

→ Evaluar potencial

Inversión selectiva

🐶 DOGS

Bajo CAGR · Baja participación

→ Revisar descontinuación

Eliminar descuentos

🚨 Tables y Bookcases (Dogs): profit total NEGATIVO. Descuento promedio >29%. Más del 55% de sus ventas generan pérdida. Recomendación: eliminar descuentos y evaluar reestructura de precios.

5

Insight 3 — Estacionalidad y Optimización de Márgenes

Análisis mes a mes del profit y descuento promedio 2020–2023

📈 Marzo: Mes de Mayor Margen

Marzo registra el margen más alto del año. Factores: menor presión de descuento y mayor proporción de ventas en categorías de alto valor (Technology). → Replicar sus condiciones en otros meses.

⚠️ Paradoja Q4: Volumen ≠ Rentabilidad

Noviembre y Diciembre concentran el mayor volumen de ventas del año, pero tienen los márgenes más bajos por descuentos excesivos. La simulación muestra que limitar descuentos a 15% en Q4 mejora el profit significativamente sin sacrificar volumen.

Conclusión Global — Los Insights 1, 2 y 3 apuntan al mismo origen:

El problema no es cuánto se vende, sino a qué precio efectivo se vende. Los descuentos sin criterio de rentabilidad son el principal destructor de valor.

5 Conclusiones y Recomendaciones

Acciones derivadas del análisis estratégico

1

Topes duros de descuento por categoría

Furniture: máx 10% · Office Supplies: máx 15% · Technology: máx 20%.

Implementar validación en el sistema de ventas antes de confirmar orden.

2

Reestructura de productos Dog

Eliminar descuentos en Tables y Bookcases. Evaluar ajuste de precios o descontinuación.

Estas dos sub-categorías tienen profit acumulado negativo.

3

Control de descuentos en Q4

Limitar descuentos en Nov–Dic a máx 15%. El volumen Q4 no compensa la caída de margen.

Replicar condiciones de Marzo (mes de mayor margen) en otros períodos.

4

Activar el Modelo Predictivo

Usar el modelo Gradient Boosting (AUC 0.984) como sistema de alerta antes de procesar ventas.

La función predecir_rentabilidad() sugiere el descuento máximo viable por transacción.

5

Estrategia diferenciada por segmento

VIP/Champions: fidelización sin descuento. En Riesgo: campañas de reactivación.

Poco Activos: análisis de abandono. Habituales: upselling en categorías rentables.

6 Modelo de Segmentación — K-Means

Feature Engineering: 15 variables en 4 bloques temáticos

RFM — Comportamiento de Compra

recency · frequency · monetary

Conductuales (derivadas)

avg_discount · avg_profit_per_order · return_rate

avg_quantity · avg_order_gap · discount_impact

Socioeconómicas

monthly_salary · age · marital_status · credit_score

Preferencias (LabelEncoder)

preferred_category · preferred_region

Preprocesamiento aplicado

StandardScaler sobre todas las variables — K-Means usa distancias euclidianas, por lo que el escalado es obligatorio para evitar que variables con mayor magnitud dominen el clustering.

Justificación k = 4

Método del Codo (Inertia) + Silhouette Score evaluados para k=2 hasta k=10.
El estadístico sugirió k=2 (Silhouette máximo = 0.091), pero se forzó k=4 por interpretabilidad de negocio:
con 2 clusters los segmentos no son suficientemente accionables para estrategias comerciales diferenciadas.

7 Selección de k — Elbow + Silhouette

Evaluación de k=2 a k=10 para determinar el número óptimo de clusters

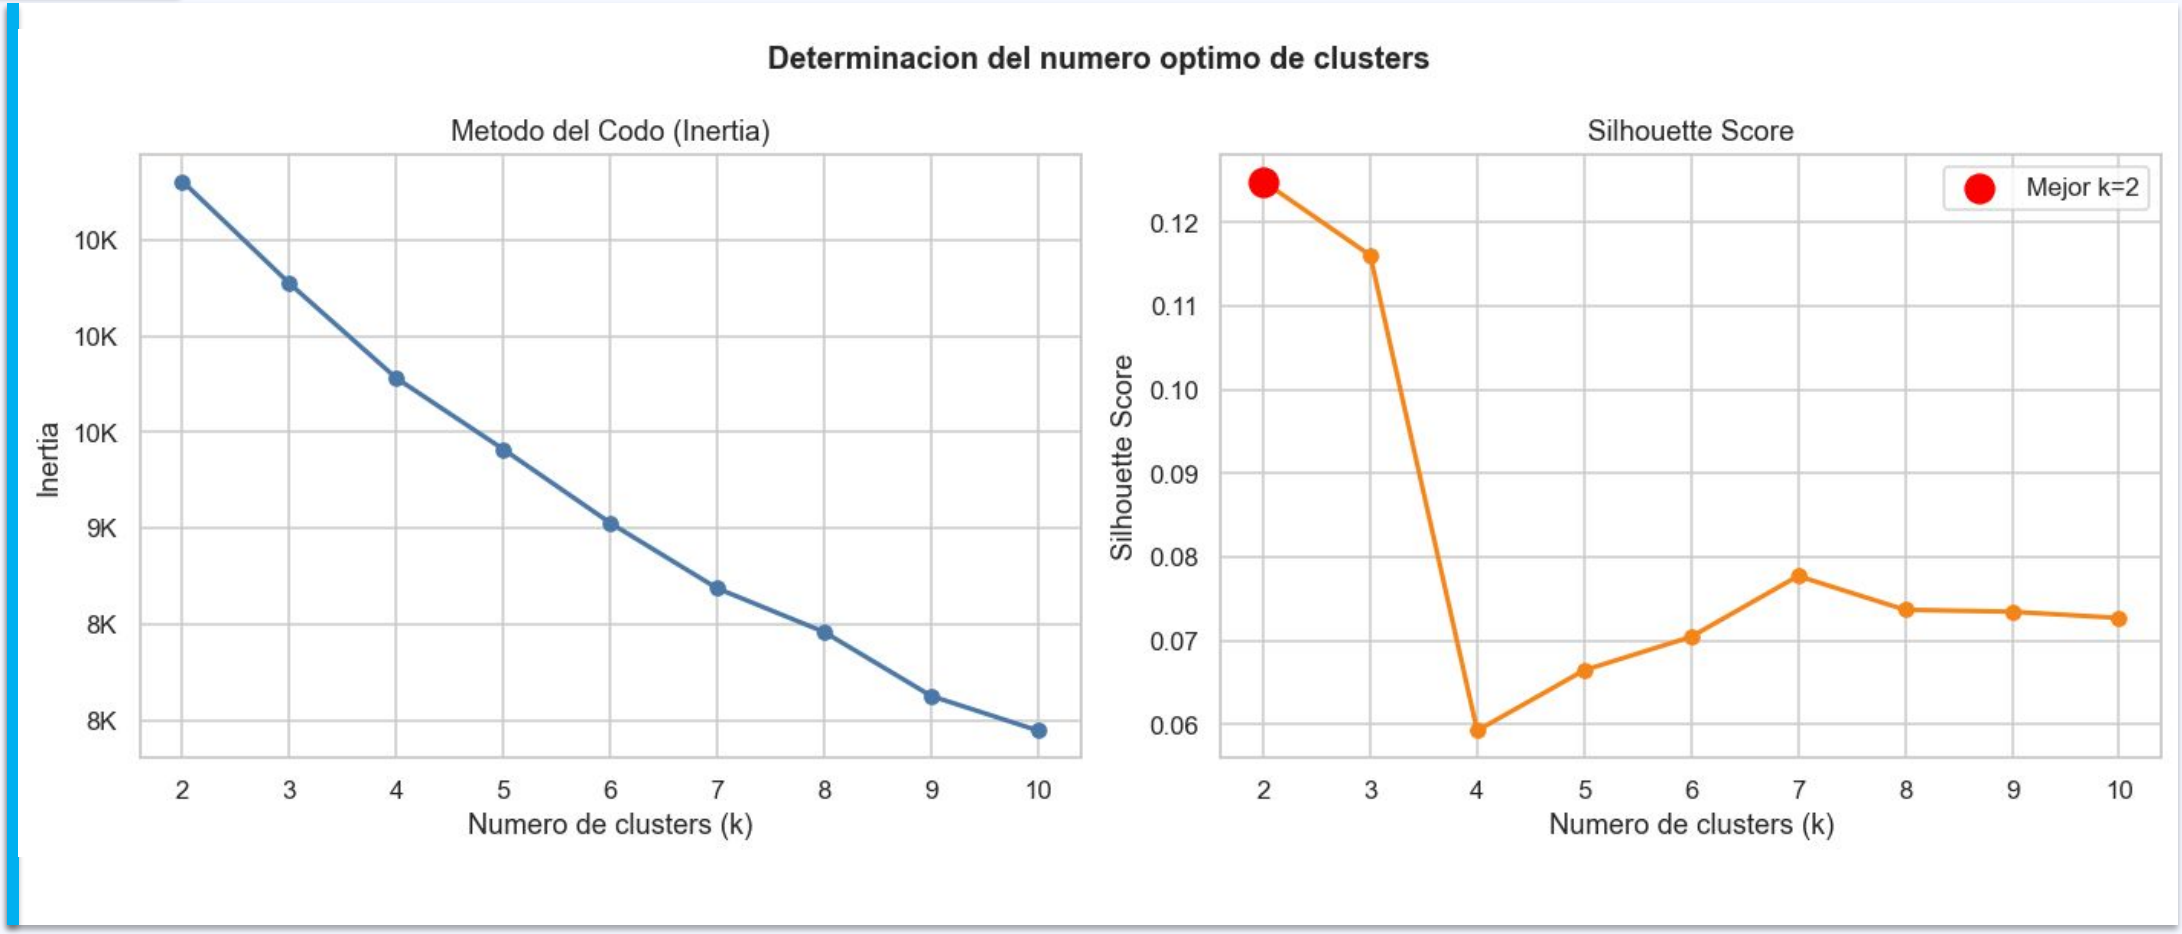

Inertia decrece significativamente hasta k=4, luego se aplana. Silhouette Score más alto en k=2, pero k=4 ofrece mayor valor de negocio.

7 Separación Visual de Clusters

Scatter plots y heatmap de perfil normalizado por segmento

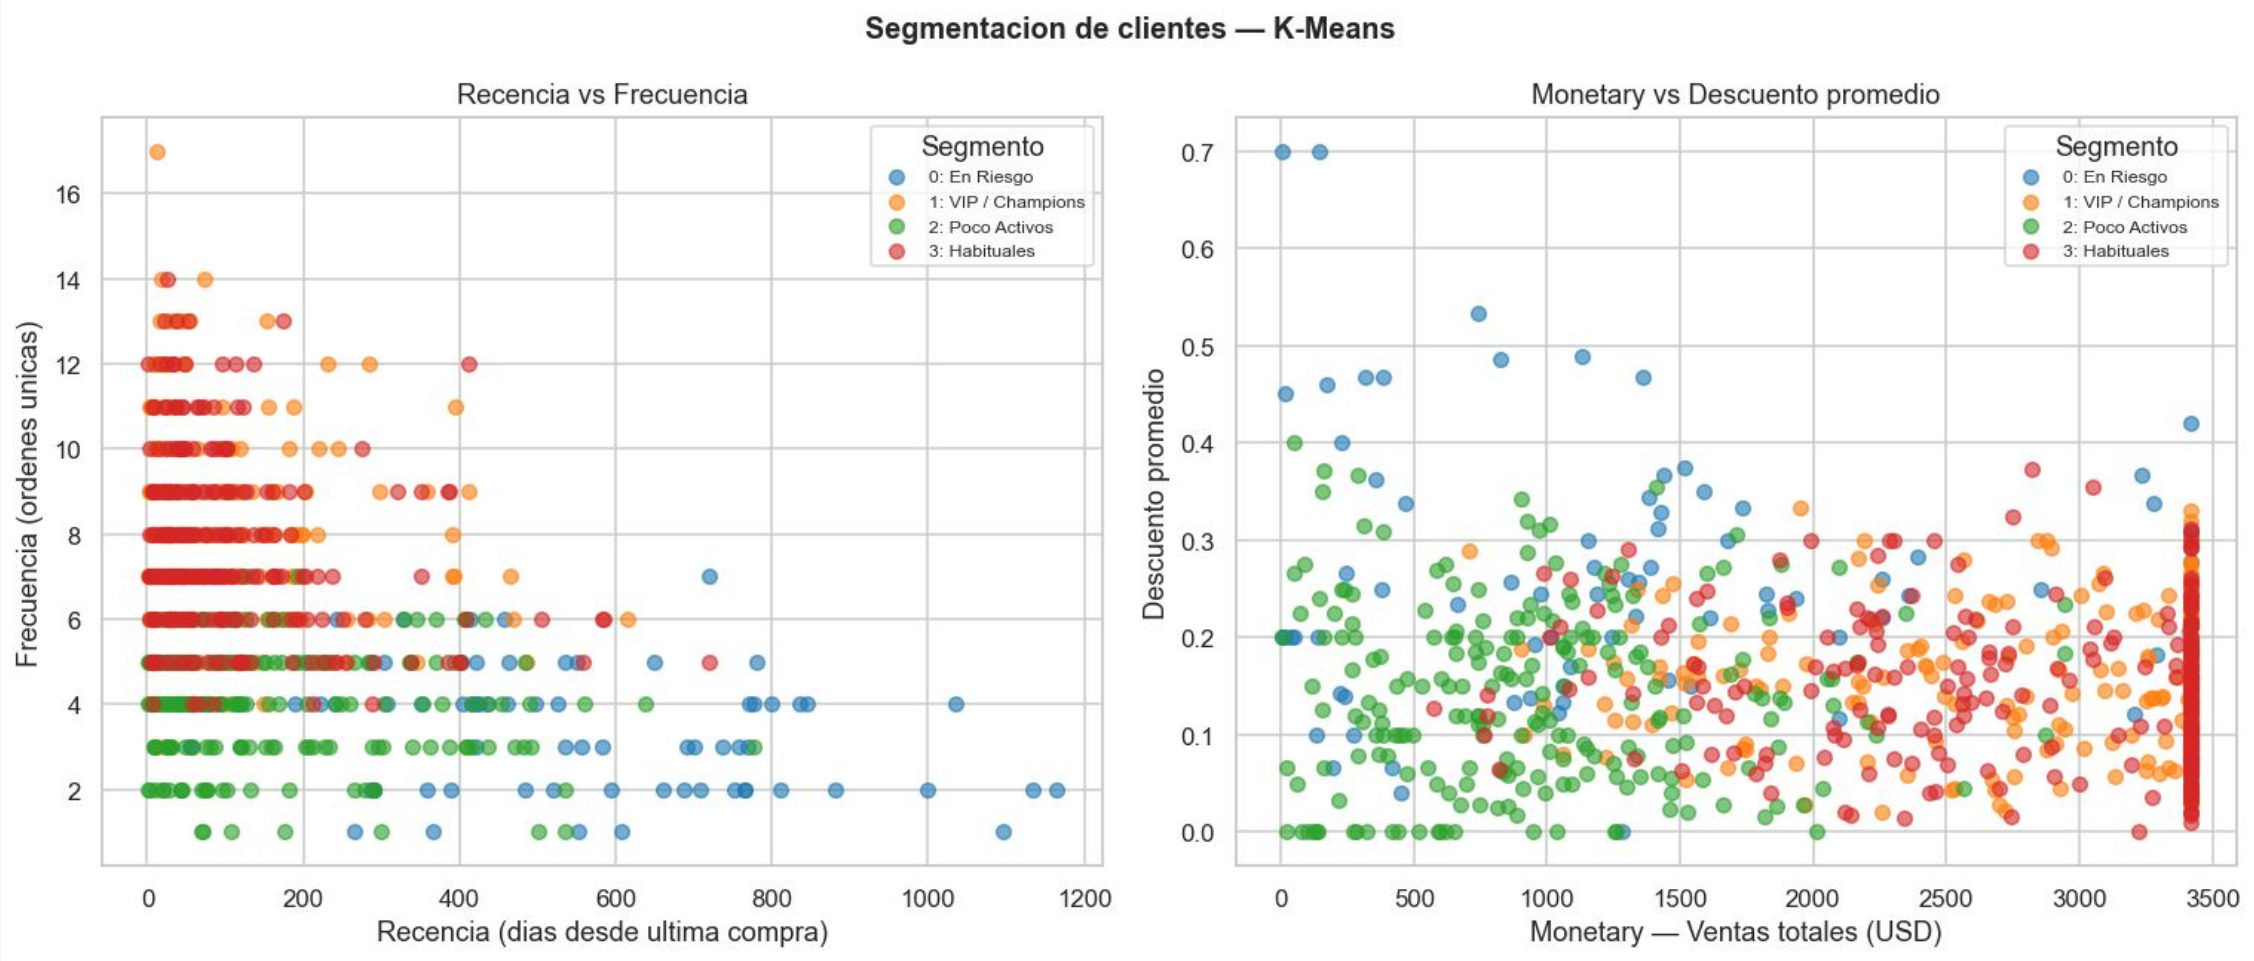

Recencia vs Frecuencia · Monetary vs Descuento

7 Separación Visual de Clusters

Scatter plots y heatmap de perfil normalizado por segmento

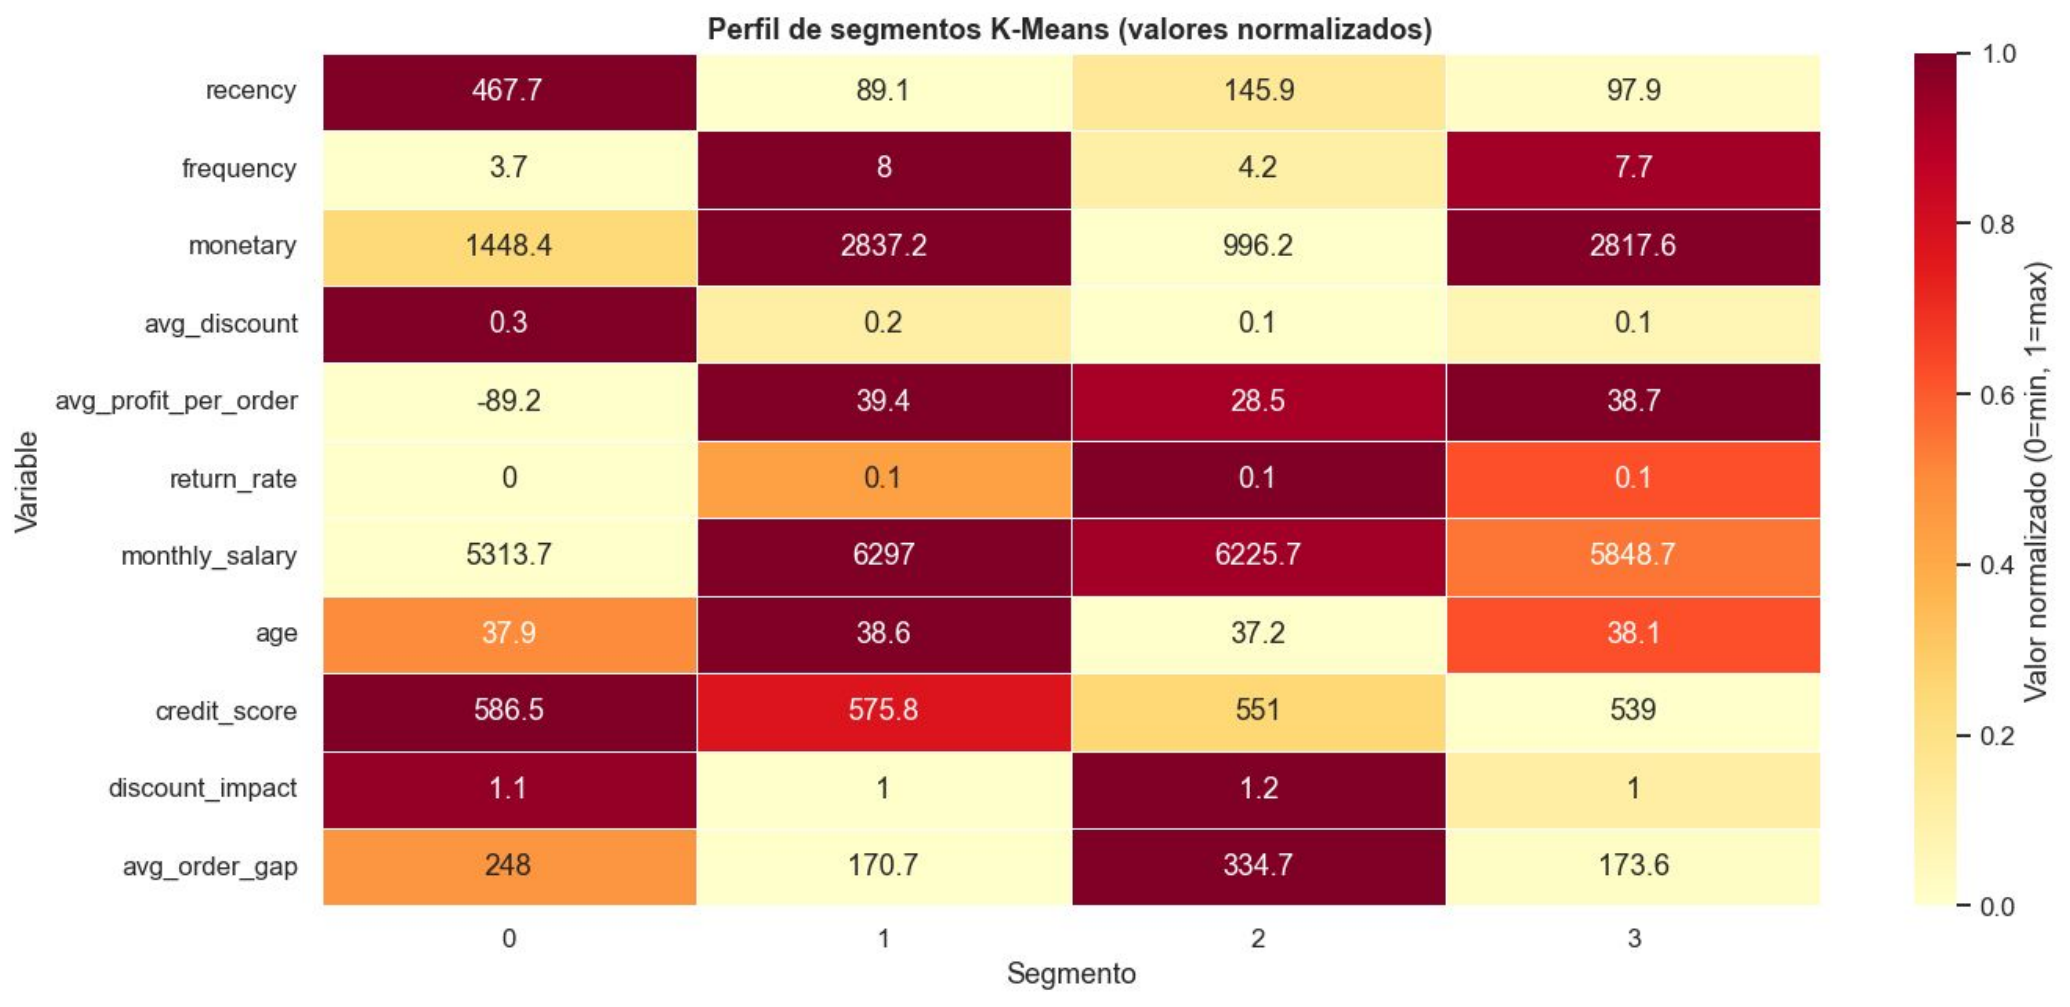

Perfil normalizado — todas las variables

7

Perfil de Segmentos — RFM y Radar

Comportamiento de cada cluster en las variables más relevantes

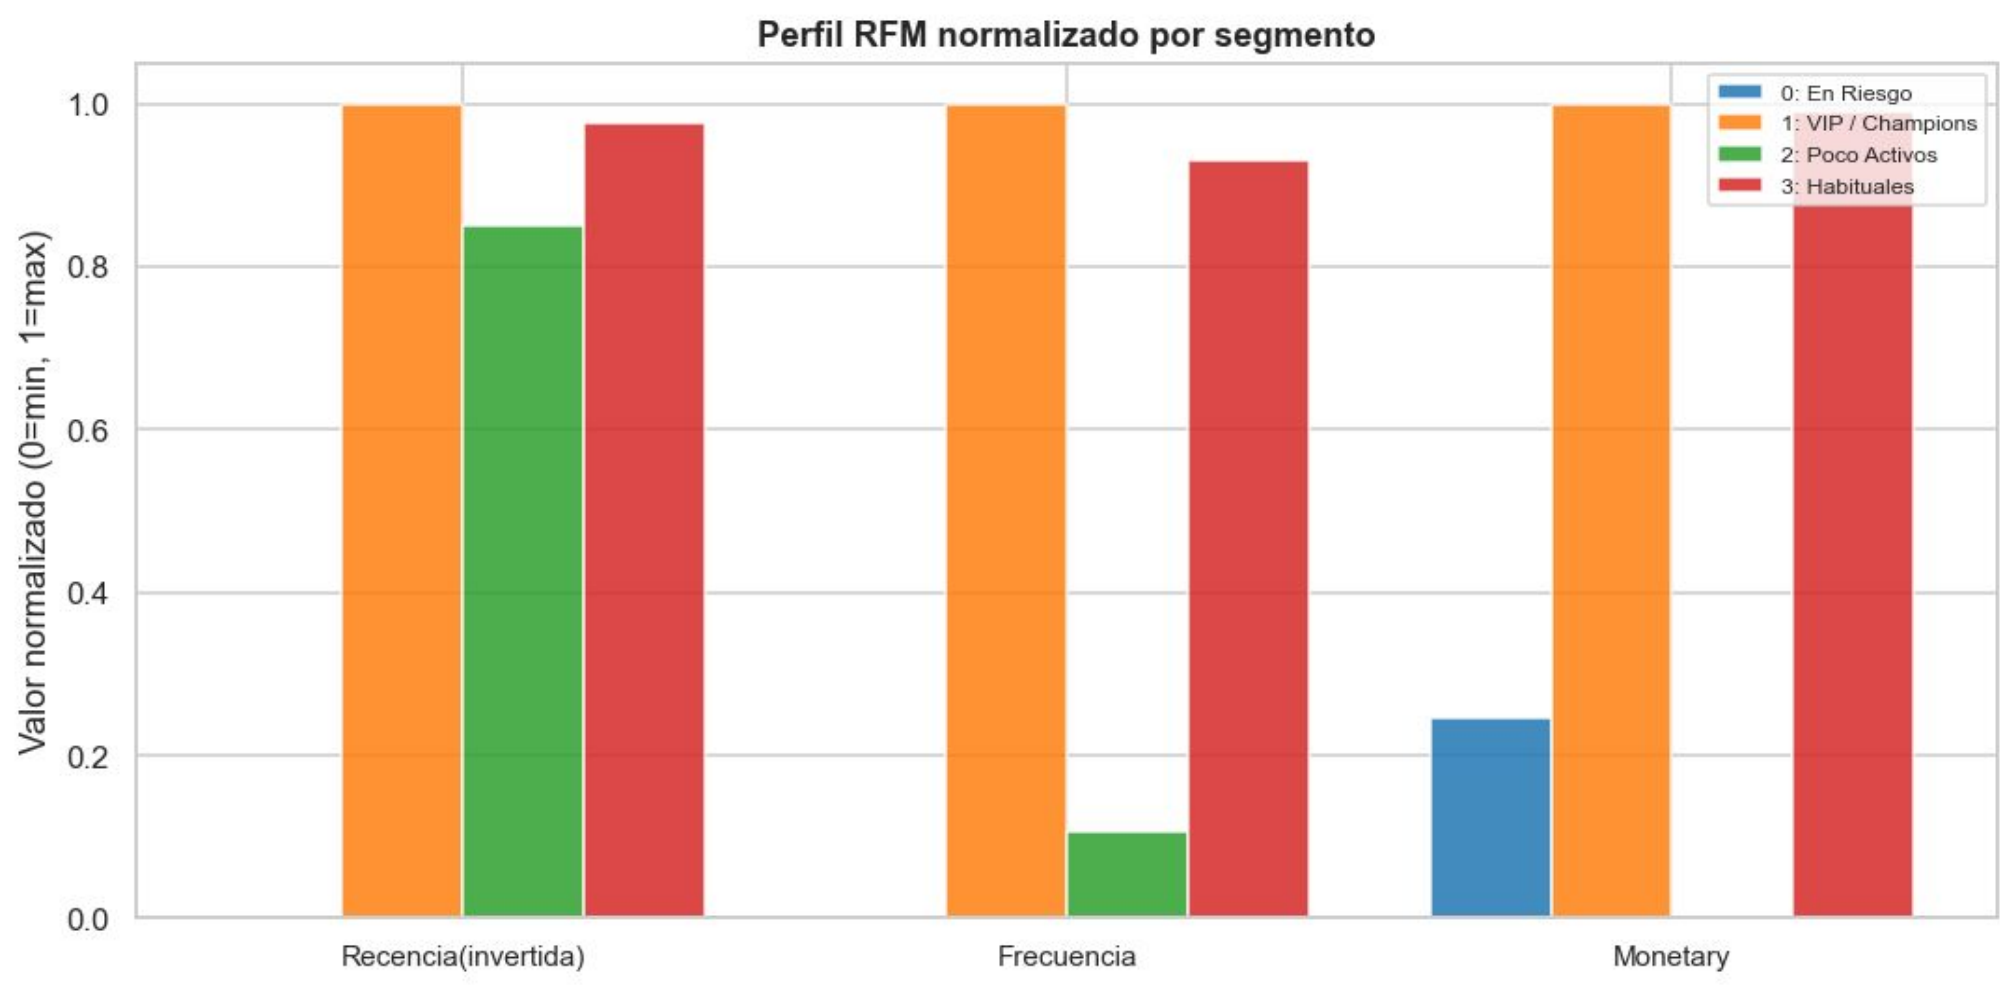

RFM normalizado por segmento (Recencia invertida)

7

Perfil de Segmentos — RFM y Radar

Comportamiento de cada cluster en las variables más relevantes

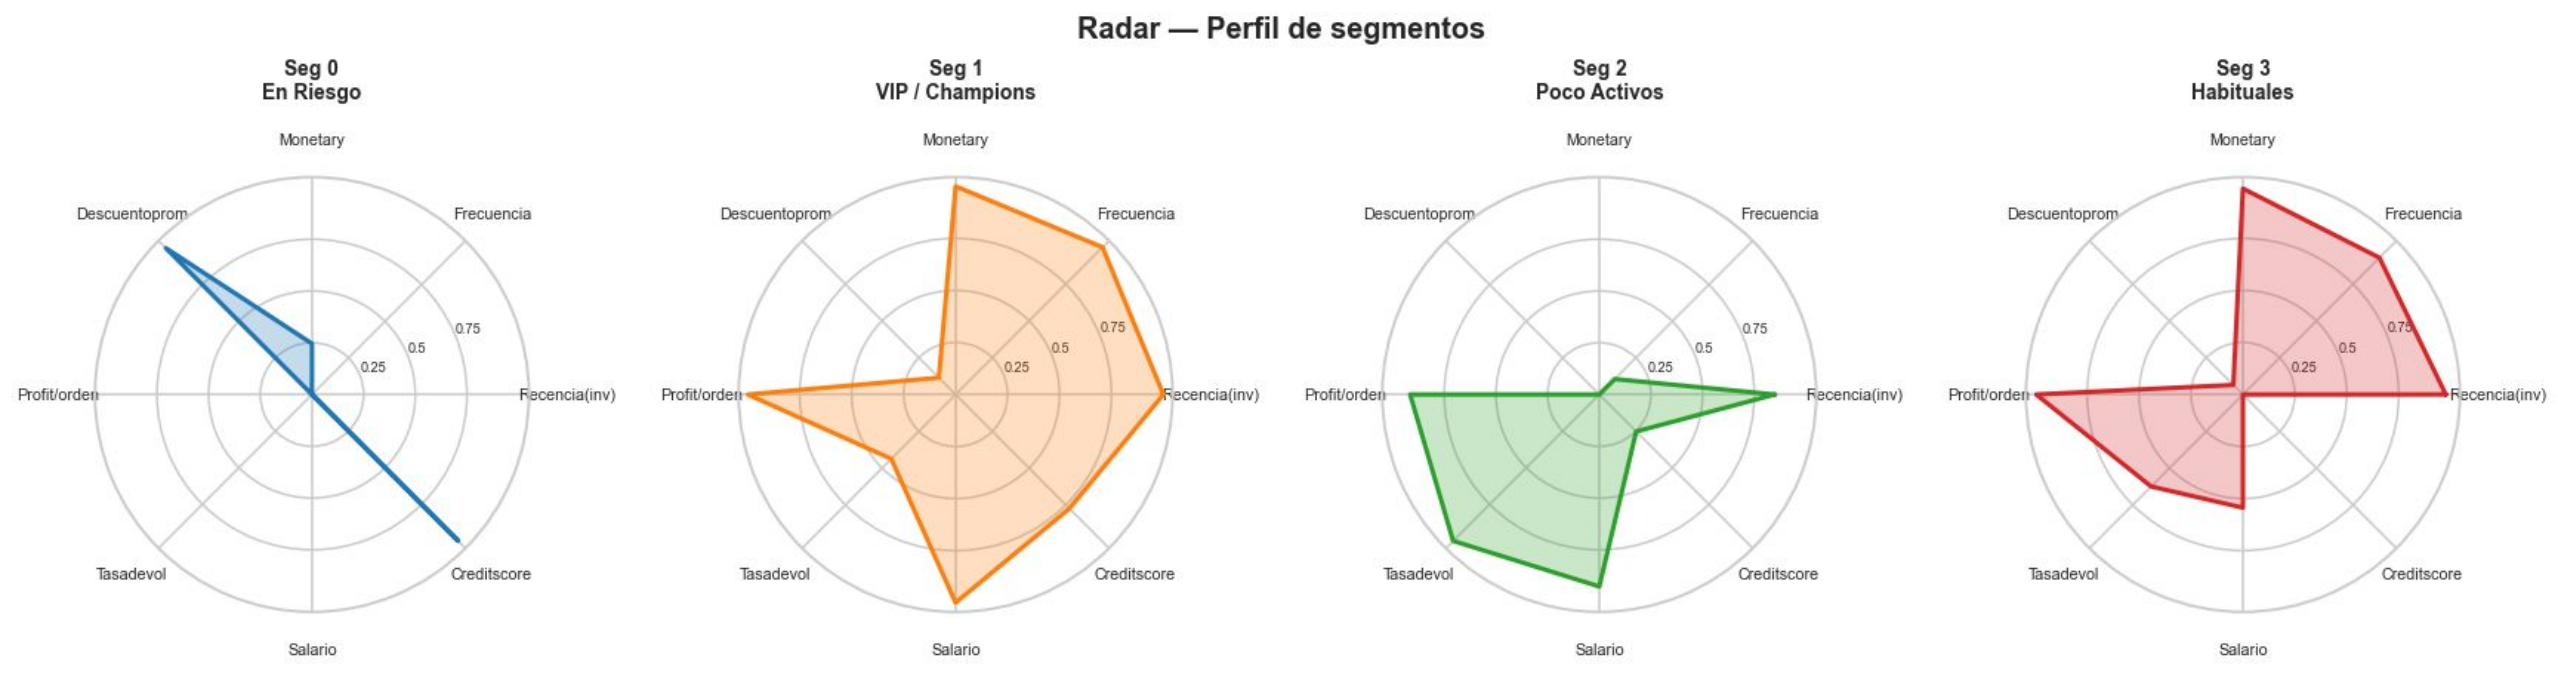

Radar — 8 variables por segmento

7

Perfiles Finales de Segmentos

Resumen cuantitativo de cada cluster después de la winsorización

Segmento	Recency	Frequency	Monetary	Profit/Orden	Estrategia
🔴 **VIP / Champions**	111 días	7.9	$7,698	$221.5	Fidelizar — mayor ROI por cliente
🟢 **Habituales**	73 días	8.3	$3,010	$33.8	Mantener — activos y rentables
🟠 **En Riesgo**	139 días	4.3	$1,369	$47.8	Retener — frecuencia decayendo
🔵 **Poco Activos**	427 días	3.9	$1,735	−$46.7	Revisar — profit negativo

8

Modelo ML — Definición del Problema

Clasificación binaria: predecir si una venta será rentable o no

Variable Objetivo: is_profitable

1 = Profit > 0 (Venta rentable) | 0 = Profit ≤ 0 (Venta con pérdida)

8,506	2,023	628	$145,507
Ventas Rentables	Ventas con Pérdida	Pérdidas Severas (Profit < −$40)	Pérdida Total Acumulada
80.8%	19.2%	6.0%	impacto

Dataset desbalanceado (80/20) ⟶ se aplicó SMOTE en el conjunto de entrenamiento para equilibrar clases al 50/50, manteniendo el test set con proporciones reales para una evaluación honesta.

8

Variables del Modelo ML — 34 Features

Combinación de variables numéricas y dummies (One-Hot Encoding)

7 Variables Numéricas Directas

- Discount
- Quantity
- Sales
- Year
- Month
- Quarter
- is_high_discount (Discount > 0.3)

27 Variables Dummy (One-Hot Encoding)

- Category (2 dummies)
- Sub_Category (16 dummies)
- Region (3 dummies)
- Ship_Mode (3 dummies)
- segment_name (3 dummies)
-

5 columnas → 27 binarias

Split estratificado 80/20 — Train: 8,423 registros · Test: 2,106 registros · Proporción de pérdidas conservada: 19.2% en ambos sets

9

Preprocesamiento — Winsorización y SMOTE

Tratamiento de asimetría y desbalance de clases

Winsorización — Percentil 70

Aplicada en: monetary y avg_profit_per_order

(Notebook 03 — modelo de segmentación K-Means)

Problema: asimetría positiva severa — media >90% por encima de la mediana en monetary.

P70 fue el óptimo: diferencia media/mediana < 15%.

Efecto: 241 clientes (29.8%) con valores recortados.

Resultado: VIP cluster monetary $2,837 → $7,698.

SMOTE — Balanceo de Clases

Aplicado solo en: conjunto de entrenamiento

Antes: 6,805 rentables vs 1,618 pérdidas (80.8% / 19.2%)

Después: 6,805 rentables vs 6,805 pérdidas (50% / 50%) — 5,187 registros sintéticos

Test set intacto (19.2%) — representa la realidad.

El modelo se evalúa en condiciones reales.

Pipeline del Modelo

Datos originales → Feature Engineering (34 variables) → One-Hot Encoding → Split 80/20 → SMOTE (solo train) → Entrenamiento → Evaluación en test real

3 modelos entrenados: Logistic Regression · Random Forest · Gradient Boosting

10

Análisis del Target y Descuento

Distribución de la variable objetivo y relación con el descuento

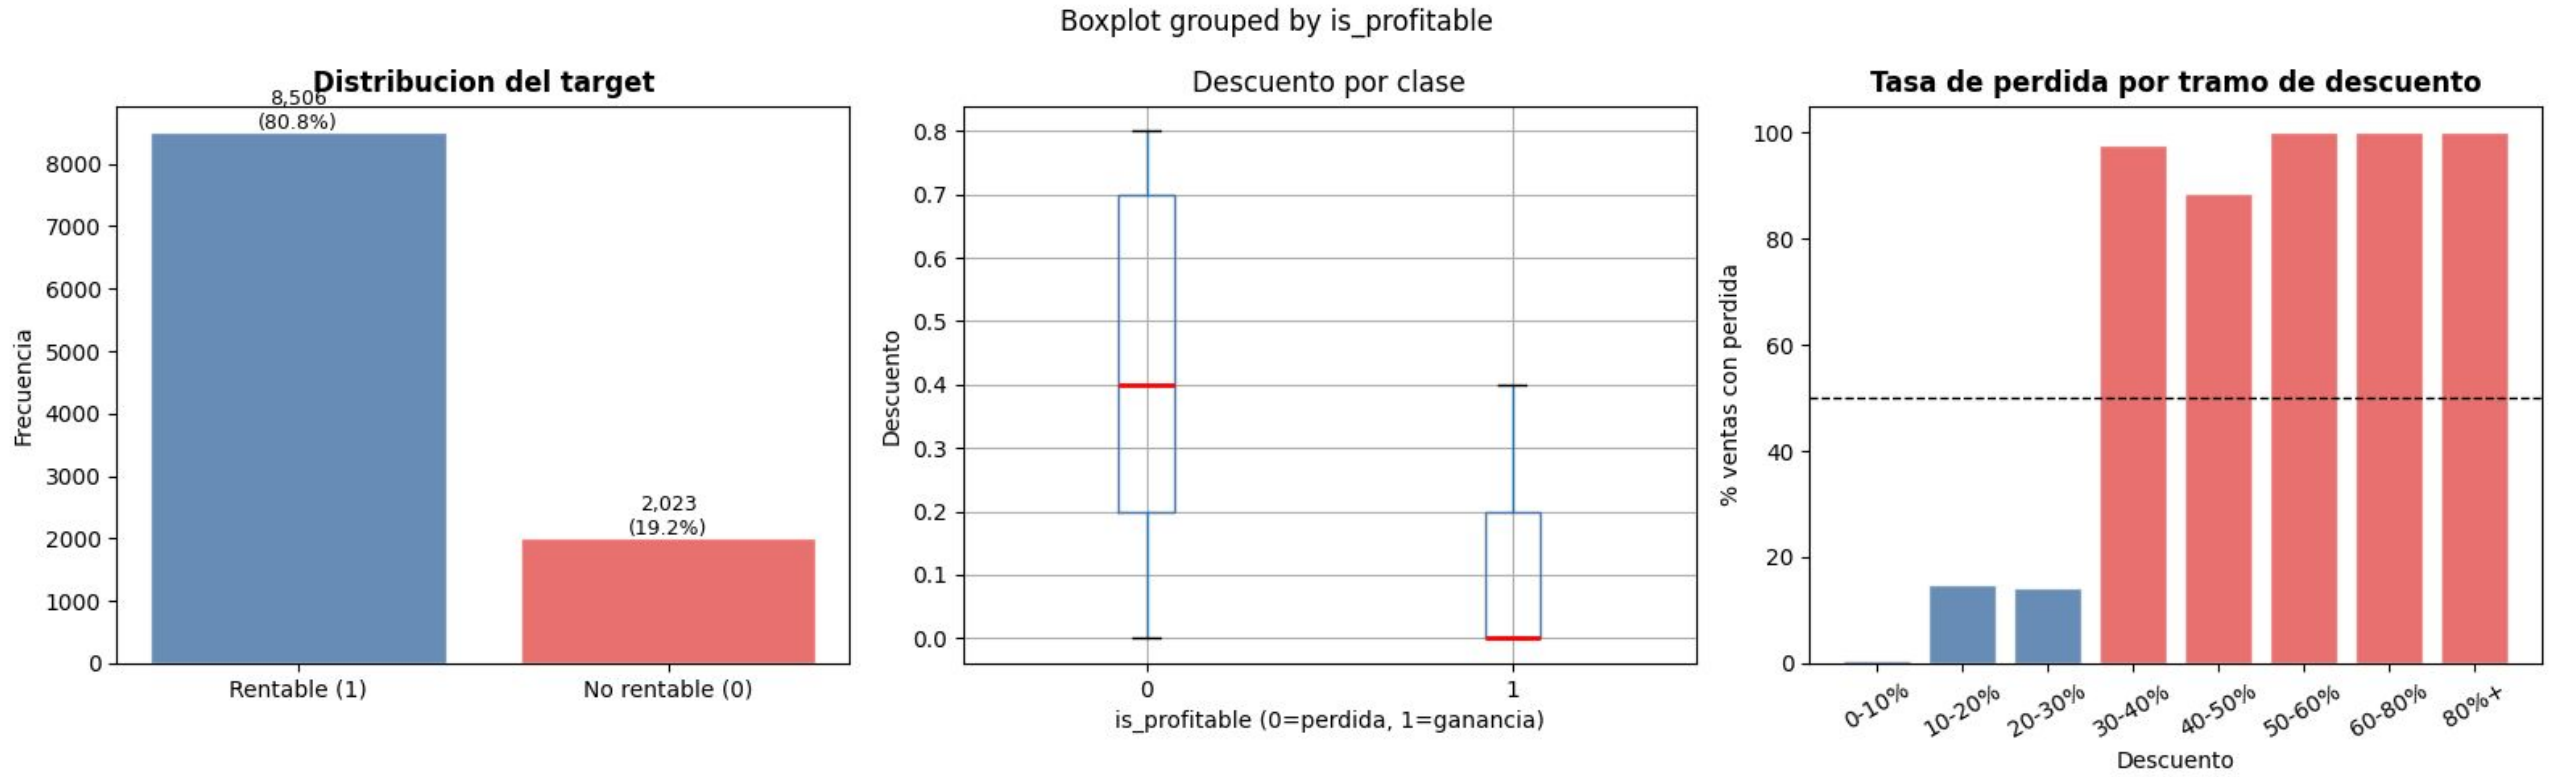

Panel 1: Distribución rentable vs no rentable · Panel 2: Boxplot descuento por clase · Panel 3: Tasa de pérdida por tramo de descuento

10

Comparación de Modelos ML

Métricas en el conjunto de test — clase No Rentable (la crítica)

Modelo	Logistic Regression	Random Forest	Gradient Boosting ★
AUC-ROC	0.974	0.977	**0.984**
Recall	0.817	0.785	**0.830**
Precision	0.830	0.901	**0.887**
F1-Score	0.823	0.839	**0.857**
Accuracy	93%	94%	**95%**

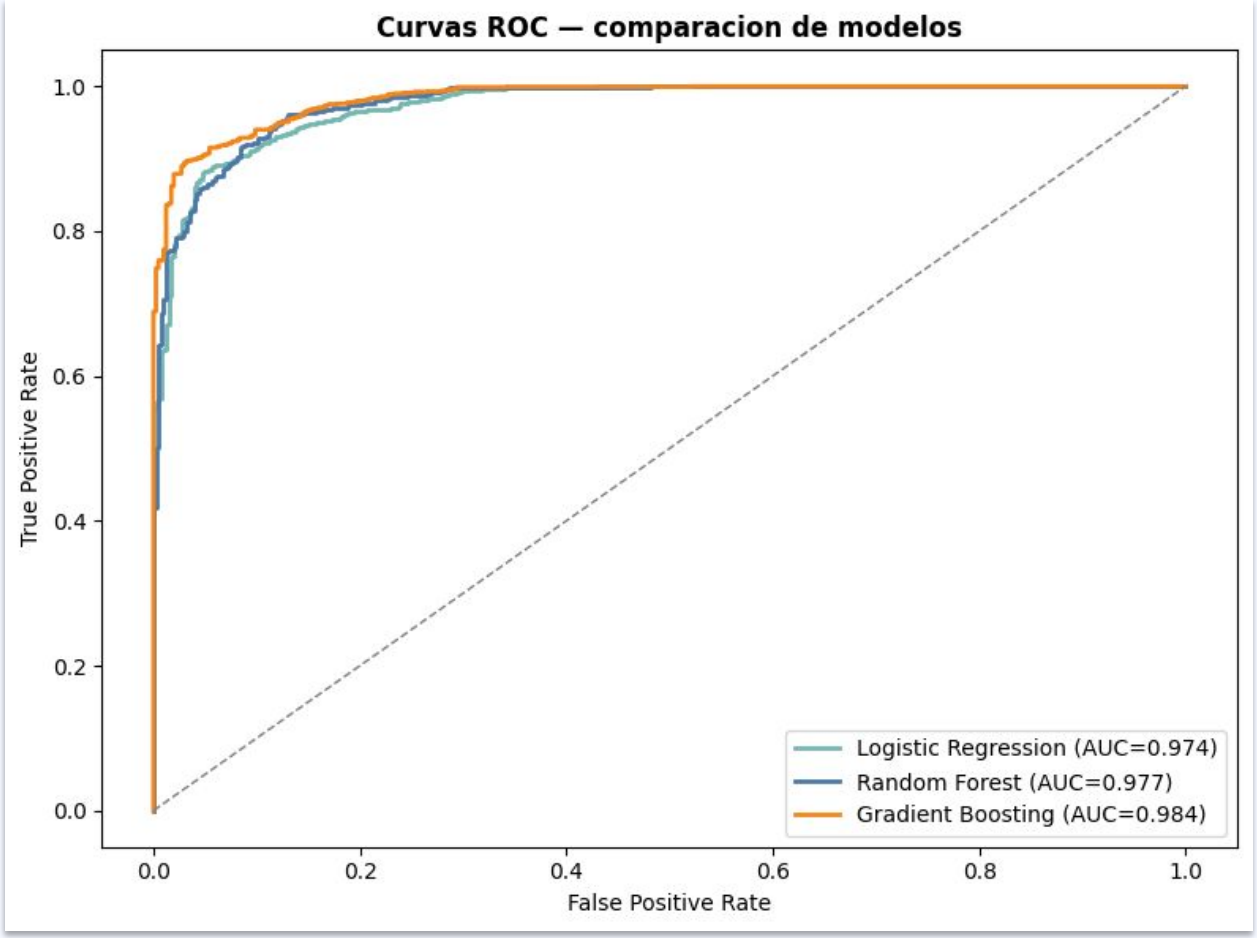

10

Gradient Boosting — Evaluación Visual

Matriz de confusión y variables más importantes

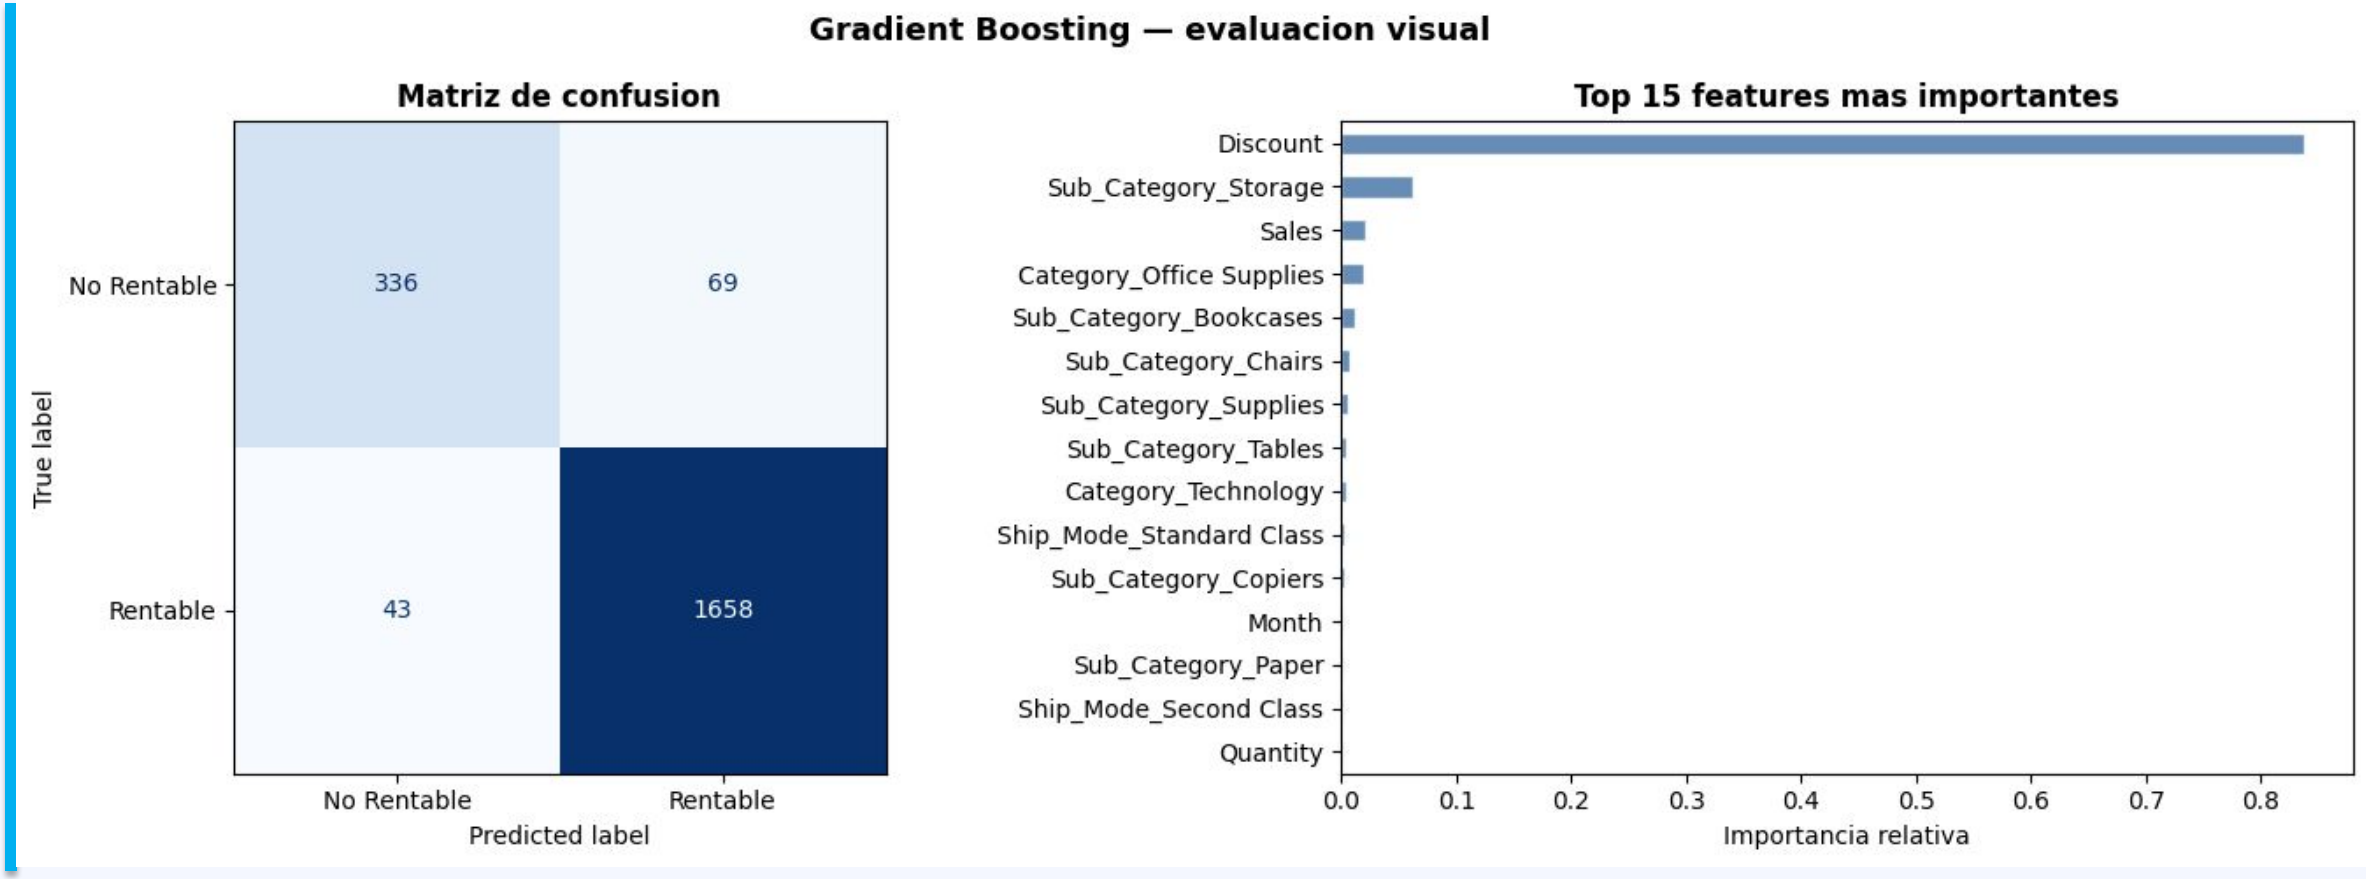

Aciertos: 1,984 / 2,106 (94.2%) · Falsos Negativos: 69 ventas en pérdida no detectadas

Discount e is_high_discount explican ~70% de la decisión del modelo ⟶ el descuento es el predictor dominante

CONCLUSIONES FINALES

El Descuento es el Centro del Problema

EDA + Insights	El descuento >30% destruye rentabilidad en todas las categorías. Tables y Bookcases son Dogs con profit acumulado negativo.
Segmentación	4 segmentos accionables: VIP ($7,698 monetary, profit $221), Habituales, En Riesgo y Poco Activos con profit negativo.
Modelo ML	Gradient Boosting AUC 0.984 · F1 0.857 en clase crítica · 94.2% de accuracy. Sistema de alerta confiable
Impacto Potencial	El modelo identifica el 83% de las ventas con pérdida antes de procesarlas. Ahorro potencial estimado sobre $145,507 en pérdidas.